مستندات: تحلیل احساسات نظرات اسنپ‌فود با ParsBERT

Nov 6, 2026 · @Pourya

خلاصه پروژه

این پروژه مدل ParsBERT را برای طبقه‌بندی دودویی احساسات (HAPPY / SAD) نظرات فارسی اسنپ‌فود فاین‌تیون می‌کند و روی مجموعه test به دقت ۸۷.۲۱٪ و macro F1 برابر ۸۷.۱۸٪ می‌رسد.

- **کد:** نوتبوک روی گیت‌هاب
- **دیتاست:** ParsiAI/snappfood-sentiment-analysis
- **مدل پایه:** HooshvareLab/bert-fa-base-uncased
- **محیط اجرا:** Google Colab با GPU مدل T4، حدود ۲۰ دقیقه برای هر epoch
- **بهترین checkpoint:** مربوط به epoch اول (macro F1 روی validation برابر ۸۷.۵۳٪)

دیتاست

کلاس‌ها تقریباً متوازن‌اند (۵۰.۳۵٪ HAPPY در برابر ۴۹.۶۵٪ SAD در train) و مجموعه train مقدار گمشده و کامنت تکراری ندارد. ستون‌ها: `comment` (متن)، `label` (HAPPY یا SAD) و `label_id` (HAPPY = 1، SAD = 0).

مجموعه	تعداد نمونه	HAPPY	SAD
train	52,110	26,236	25,874
validation	8,337		
test	9,033	4,486	4,547

طول کامنت‌ها (تعداد کاراکتر، فقط روی train): میانگین ۸۹.۹، میانه ۶۶، چارک سوم ۱۱۴، حداکثر ۱۷۰۰، حداقل ۱۱ کاراکتر است. با `MAX_LENGTH = 128` توکن، تعداد کمی از کامنت‌های بلند بریده می‌شوند.

توجه: بررسی مقادیر گمشده و تکراری فقط روی train انجام شده و توزیع کلاس‌های validation در نوتبوک چاپ نشده است.

مدل و تنظیمات آموزش

مدل `bert-fa-base-uncased` با یک لایه طبقه‌بندی دوکلاسه (`AutoModelForSequenceClassification`) فاین‌تیون شده است. لایه classifier از ابتدا مقداردهی می‌شود و هدهای pretraining در checkpoint نادیده گرفته می‌شوند. هر دو مورد در گزارش بارگذاری

نوتبوک آمده و عادی‌اند.

پارامتر	مقدار
حداکثر طول توکن	128 (truncation + padding به max_length)
batch size	16 (3,257 گام در هر epoch)
تعداد epoch	حداکثر 4، با early stopping
Optimizer	AdamW، learning rate برابر 2e-5، weight decay برابر 0.01
Scheduler	warmup خطی برای 10٪ گام‌ها (حدود 1,302 از 13,028)، سپس کاهش خطی
Gradient clipping	max_norm برابر 1.0
Early stopping	بر اساس macro F1 روی validation، patience برابر 2
سخت‌افزار	Google Colab، GPU مدل T4

بهترین مدل (بر اساس val macro F1) در `outputs/best_model` ذخیره می‌شود و ارزیابی نهایی روی test با همان checkpoint انجام شده است. چون scheduler برای 4 epoch تنظیم شده بود ولی آموزش بعد از 3 epoch متوقف شد، learning rate هرگز به صفر نرسید.

روند آموزش

بهترین validation macro F1 (۸۷.۵۳٪) در epoch اول به دست آمد و در دو epoch بعد بهتر نشد، پس early stopping بعد از 3 epoch آموزش را متوقف کرد (epoch چهارم اجرا نشد).

Epoch	Train loss	Val loss	Val accuracy	Val macro F1	نتیجه
1	0.3618	0.3356	0.8756	0.8753	ذخیره به‌عنوان بهترین مدل
2	0.2783	0.3155	0.8732	0.8731	بدون بهبود
3	0.2172	0.3824	0.8693	0.8688	بدون بهبود، توقف

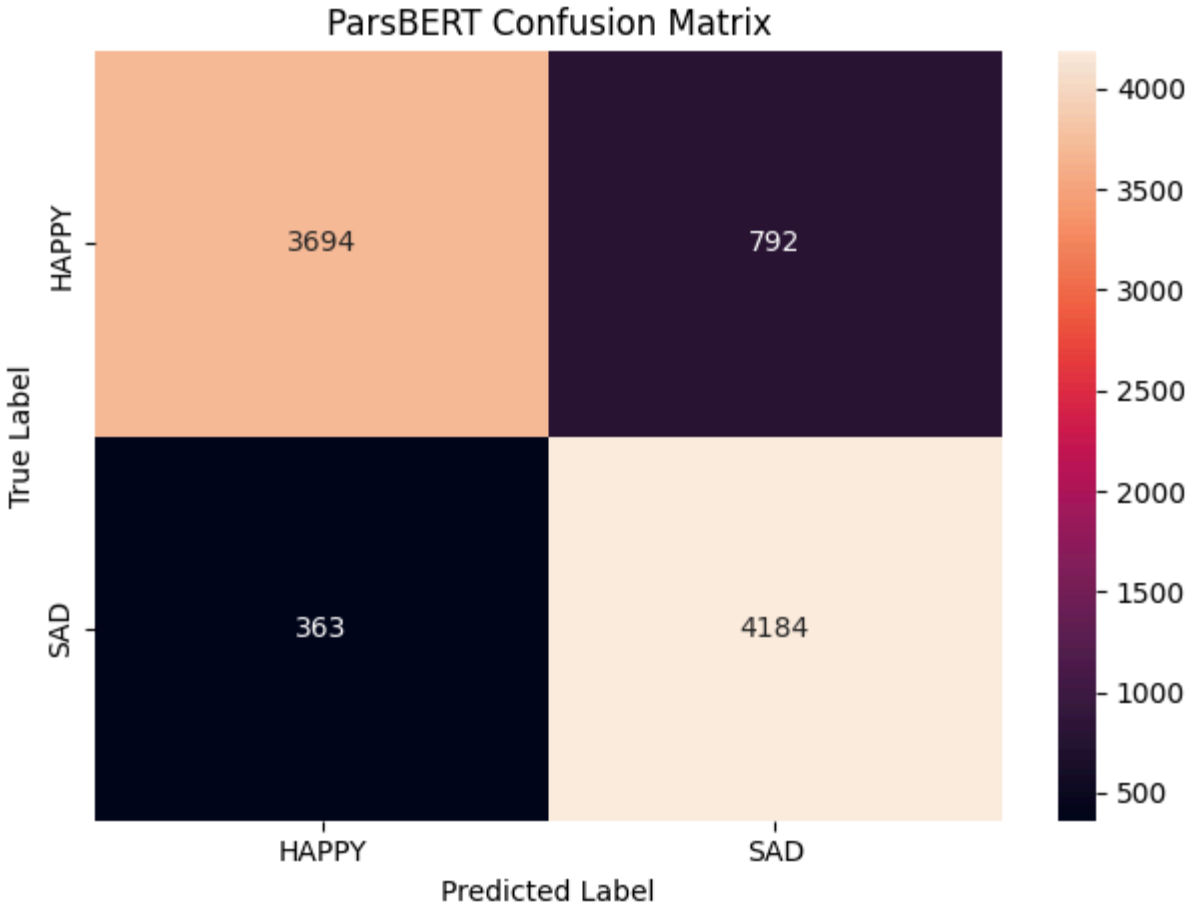
Train loss در هر epoch کم شده ولی val loss در epoch 3 بالا رفته و val F1 بعد از epoch 1 نزولی بوده و بهتر F1 کمتر بود و فقط val loss از epoch 1 مقدار epoch 2 است. در overfitting است. این الگو نشانه overfitting مربوط به epoch 3 است. پس شواهد قوی نشد،.

نتایج روی test

مدل روی ۹,۰۳۳ نمونه test به دقت ۸۷.۲۱٪ و macro F1 برابر ۸۷.۱۸٪ می‌رسد که فقط حدود ۰.۳۵ واحد کمتر از validation (۸۷.۵۳٪) است. Test loss برابر ۰.۳۴۰۷ است.

کلاس	Precision	Recall	F1	Support
HAPPY	0.9105	0.8235	0.8648	4,486
SAD	0.8408	0.9202	0.8787	4,547
Macro avg	0.8757	0.8718	0.8718	9,033
Weighted avg	0.8754	0.8721	0.8718	9,033

ماتریس درهم‌ریختگی :



واقعی \ پیش‌بینی	HAPPY	SAD
HAPPY	3,694	792
SAD	363	4,184

مدل کامنت‌های HAPPY را بیشتر به‌اشتباه SAD برچسب می‌زند (۷۹۲ از ۴,۴۸۶ یا حدود ۱۷.۷٪) تا برعکس (۳۶۳ از ۴,۵۴۷ یا حدود ۸.۰٪). به همین دلیل precision کلاس HAPPY بالا و recall آن پایین است و بهبود recall کلاس HAPPY اولین هدف منطقی برای مدل‌های بعدی است.

تناقض‌ها فقط در سه سلول توضیحی (markdown) هستند. کد و خروجی‌ها با هم می‌خوانند، پس باید متن‌ها با خروجی واقعی هماهنگ شوند.ساختار ریپو و گام‌های بعدی

بهتر است هر روش یک نوتبوک جدا داشته باشد و همه روی همان splitهای دیتاست اجرا شوند تا نتایج قابل مقایسه بمانند.

وضعیت	نوتبوک	روش
انجام شد	`notebooks/parsbert.ipynb`	فاین‌تیون ParsBERT
برنامه‌ریزی‌شده	`notebooks/svm_tfidf.ipynb`	TF-IDF با ویژگی‌های SVM
برنامه‌ریزی‌شده	`notebooks/cnn.ipynb`	استخراج ویژگی با CNN

پوشه‌ها: `notebooks/` برای نوتبوک‌ها، `outputs/` برای confusion matrix و متریک‌های ذخیره‌شده، و `README.md` با جدول نتایج که هر روش جدید یک ردیف به آن اضافه می‌کند.

نکات برای مقایسه منصفانه:

- انتخاب مدل و تنظیم هایپرپارامترها فقط با validation انجام شود و test فقط یک‌بار برای گزارش نهایی استفاده شود.
- همه مدل‌ها با همان متریک‌ها (accuracy، macro precision، recall و F1) و همان `classification_report` ارزیابی شوند.
- برای مدل‌های کلاسیک، پیش‌پردازش متن فارسی (نرمال‌سازی نویسه‌ها و فاصله‌ها) را در همان نوتبوک مستند کن، چون روی نتیجه اثر دارد.
- در ParsBERT، recall کلاس HAPPY (۸۲.۳۵٪) ضعیف‌ترین نقطه است. تنظیم learning rate یا تعداد epoch و بررسی خطاهای کلاس HAPPY نقطه شروع مناسبی هستند.